

BİTİRME PROJESİ: Film / Kitap Öneri Sistemi

Kullanıcı puanlarına göre tavsiye sistemi geliştirme projesi

Amaç

Kullanıcının verdiği puanlardan hareketle sevebileceği film veya kitapları önermek.

Temel Araçlar

pandas, numpy, cosine similarity, isteğe bağlı scikit-learn

Yaklaşım

Kullanıcı-benzerliği ve içerik-benzerliği mantığını anlamak ve uygulamak.

Seviye

Başlangıç-orta seviye veri bilimi / makine öğrenimi öğrencileri



Bu f6y, 6ğrencinin sıfırdan başlayarak veri okuma, pivot tablo oluřturma, benzerlik hesaplama, 6neri 6retme ve sonuřları yorumlama ařamalarını d6zenli biřimde tamamlayabilmesi iřin hazırlanmıřtır.

1. Projenin amacı ve senaryosu

Bu projede öğrenciden beklenen temel iş, kullanıcıların geçmişte verdiği puanları kullanarak onlara yeni film veya kitap önerileri sunan bir sistem geliştirmesidir. Örneğin bir kullanıcı bazı filmlere 5 puan, bazılarına 2 puan vermiş olabilir. Sistem, benzer zevke sahip diğer kullanıcıları bularak veya benzer içerikleri eşleştirerek yeni tavsiyeler üretir.

Buradaki ana fikir şudur: Bir kullanıcının geçmiş davranışı, gelecekte neyi sevebileceği hakkında ipucu verir. Bu nedenle proje, veri analizi ile makine öğrenimi arasındaki bağlantıyı çok iyi gösterir. Öğrenci sadece kod yazmayı değil; aynı zamanda verinin neden önemli olduğunu, benzerlik kavramının nasıl çalıştığını ve sonuçların nasıl yorumlanacağını da öğrenir.

2. Öğrencinin bu projede kazanacağı beceriler

- pandas ile CSV veri seti okuma, filtreleme, birleştirme ve özetleme
- numpy ile sayısal işlemler, dizi mantığı ve benzerlik hesabına hazırlık
- Pivot tablo oluşturarak kullanıcı-içerik matrisi kurma
- Cosine similarity mantığını kavrama ve benzerlik skoru üretme
- Kullanıcı tabanlı (user-based) ve içerik tabanlı (item-based) öneri sistemlerini ayırt etme
- Eksik puanlar, seyrek veri ve soğuk başlangıç gibi temel öneri sistemi problemlerini fark etme
- Sonuçları tablo, grafik ve kısa bir proje raporu ile sunma

3. Kullanılacak kütüphaneler

Kütüphane	Ne için kullanılır?	Not
pandas	Veri okuma, temizleme, pivot tablo, groupby işlemleri	Bu proje için zorunlu
numpy	Sayısal işlemler, matris mantığı, NaN kontrolü	Bu proje için zorunlu
scikit-learn	Cosine similarity veya yardımcı metrikler	İsteğe bağlı ama önerilir
matplotlib / seaborn	Grafik ve sonuç görselleştirme	Rapor kalitesini yükseltir

4. Veri seti yapısı nasıl olmalı?

Öğrencinin bu projeyi yapabilmesi için en az üç temel tabloya veya tek bir zengin veri dosyasına ihtiyacı vardır. En anlaşılır kurgu, kullanıcı puanları ile içerik bilgilerini ayrı dosyalarda tutmaktır. Böylece öğrenci hem merge işlemini hem de veri modelini öğrenir.

- ratings.csv: user_id, item_id, rating, timestamp
- items.csv: item_id, title, category, type, year
- İsteğe bağlı users.csv: user_id, age, city, favorite_genre

4.1 Örnek ratings.csv

user_id	item_id	rating	timestamp
1	101	5	2026-01-04

user_id	item_id	rating	timestamp
1	103	4	2026-01-08
2	101	4	2026-01-11
2	102	5	2026-01-15
3	103	2	2026-01-17

4.2 Örnek items.csv

item_id	title	category	type	year
101	Sefiller	Klasik	Kitap	1862
102	Interstellar	Bilim Kurgu	Film	2014
103	1984	Distopya	Kitap	1949
104	Inception	Bilim Kurgu	Film	2010

Önemli not: Kullanıcıların bütün içeriklere puan vermesi beklenmez. Zaten öneri sistemlerinin temel problemi budur. Veri tablosunda birçok boş eşleşme olacaktır. Öğrenci, bu boşlukların normal olduğunu anlamalıdır.

5. Projenin adım adım yapılacak aşamaları

Aşama 1 - Veriyi içe aktarma ve inceleme

- CSV dosyalarını pandas ile okuyun.
- İlk 5 satırı, sütun isimlerini, veri tiplerini ve eksik değerleri kontrol edin.
- Kaç kullanıcı, kaç içerik ve toplam kaç puan kaydı olduğunu bulun.

Aşama 2 - Veri temizliği

- Eksik veya hatalı kayıtları tespit edin.
- Aynı kullanıcının aynı içeriğe birden fazla kez puan verip vermediğini kontrol edin.
- Puan aralığının beklenen sınırlar içinde olup olmadığını doğrulayın. Örneğin 1-5 arası.

Aşama 3 - Kullanıcı-içerik matrisi oluşturma

- pivot_table kullanarak satırlarda kullanıcılar, sütunlarda içerikler olacak şekilde bir matris kurun.
- Hücrelerde ilgili kullanıcının o içeriğe verdiği puan yer alsın.
- Boş kalan hücreleri nasıl ele alacağınıza karar verin. Genelde 0 ile doldurma veya NaN bırakma yaklaşımı tartışılır.

Aşama 4 - Benzerlik hesabı

- Kullanıcıların birbirine benzerliğini cosine similarity ile hesaplayın.
- İsterseniz içeriklerin birbirine benzerliğini de aynı mantıkla hesaplayın.
- Benzerlik matrisi oluşturduktan sonra en yakın komşuları belirleyin.

Aşama 5 - Öneri üretme

- Bir kullanıcı için daha önce puan vermediği içerikleri filtreleyin.
- Benzer kullanıcıların sevdiği içerikleri aday öneri olarak toplayın.
- Aday içerikleri benzerlik skoruna ve puanlara göre sıralayın.

Aşama 6 - Sonuçları yorumlama

- Önerilen içerikler gerçekten mantıklı mı kontrol edin.
- En çok önerilen kategori, en aktif kullanıcı, en yüksek puanlı içerikler gibi analizler çıkarın.
- Sistemin güçlü ve zayıf yönlerini raporda anlatın.

5.1 Cosine similarity mantığı

Cosine similarity iki vektör arasındaki yön benzerliğini ölçer. Bu projede her kullanıcıyı, verdiği puanlardan oluşan bir vektör gibi düşünebiliriz. İki kullanıcının puan davranışı birbirine benziyorsa cosine similarity skoru 1 değerine yaklaşır. Davranışları farklıysa skor 0 civarına düşer.

$$\text{cosine}(A, B) = (A \cdot B) / (||A|| * ||B||)$$

Öğrencinin bu formülü ezberlemesi şart değildir; ancak mantığını anlaması gerekir. Amaç, iki kullanıcının içerik tercih yönlerinin ne kadar benzeştiğini görmektir.

6. İki farklı öneri yaklaşımı

6.1 Kullanıcı tabanlı öneri (User-Based Recommendation)

Bu yaklaşımda önce hedef kullanıcıya benzeyen diğer kullanıcılar bulunur. Daha sonra benzer kullanıcıların yüksek puan verdiği, ancak hedef kullanıcının henüz puanlamadığı içerikler önerilir. Mantık şudur: Bana benzeyen kişiler bir içeriği beğendiyse, ben de beğenebilirim.

- Avantaj: Mantığı öğrenci için oldukça anlaşılırdır.
- Dezavantaj: Kullanıcı sayısı çok büyüdüğünde hesaplama maliyeti artabilir.

6.2 İçerik tabanlı öneri (Item-Based Recommendation)

Bu yaklaşımda kullanıcılar değil, içeriklerin kendileri karşılaştırılır. Örneğin kullanıcı daha önce bilim kurgu ve yüksek puanlı birkaç film seçtiyse, bu filmlere benzeyen diğer içerikler önerilir. Mantık şudur: Daha önce sevdiğin içeriğe benzeyen başka içerikler de ilgini çekebilir.

- Avantaj: Bir kullanıcının geçmiş tercihleri güçlü ise iyi sonuç verebilir.
- Dezavantaj: Yeni içerik veya yeni kullanıcı durumunda veri az ise zorlanabilir.

6.3 Öğrenciye görev

Projede en az bir yaklaşımın mutlaka çalışır durumda olması beklenir. Güçlü öğrencilerden her iki yaklaşımı da geliştirip sonuçları karşılaştırmaları istenebilir. Böylece hangi yöntemin hangi durumda daha iyi çalıştığı tartışılabilir.

7. Örnek çalışma akışı

Aşağıdaki akış doğrudan kopyalanacak tam proje kodu değildir. Ancak öğrencinin çözümü hangi mantıkla kuracağını gösteren net bir yol haritasıdır.

- 1) ratings.csv ve items.csv dosyalarını oku
- 2) ratings ile items tablolarını birleştir
- 3) pivot_table ile user-item matrisi oluştur
- 4) cosine similarity ile kullanıcı benzerlik matrisi üret
- 5) hedef kullanıcının puanlamadığı içerikleri bul
- 6) benzer kullanıcıların yüksek puan verdiği içerikleri toplama

- 7) skor hesapla ve en iyi 5 öneriyi listele
- 8) sonuçları başlık, kategori ve skor ile ekrana yazdır

7.1 Örnek klasör yapısı

```
film_kitap_oneri_sistemi/  
|-- data/  
|   |-- ratings.csv  
|   |-- items.csv  
|-- src/  
|   |-- main.py  
|   |-- data_loader.py  
|   |-- recommender.py  
|   |-- analysis.py  
|-- outputs/  
|   |-- recommendations.csv  
|   |-- charts/  
|-- README.md
```

7.2 Öğrenciden beklenen minimum modüller

- Veri yükleme modülü: Dosyaları okuyup kontrol edecek
- Analiz modülü: İstatistik ve özet bilgiler verecek
- Öneri modülü: Benzerlik hesaplayıp tavsiye üretecek
- Ana çalışma dosyası: Süreci başlatacak ve sonuçları gösterecek

8. Beklenen çıktılar

- Kullanıcıya önerilen en az 5 film veya kitaplık bir çıktı listesi
- Öneri skorlarını veya benzerlik tabanlı sıralamayı gösteren bir tablo
- Veri seti hakkında kısa analiz: kaç kullanıcı, kaç içerik, ortalama puan, en popüler türler
- Kısa proje raporu veya README dosyası
- İsteğe bağlı: Sonuçların CSV olarak dışa aktarılması
- İsteğe bağlı: Basit menülü terminal ekranı veya küçük bir arayüz

8.1 Kullanıcıya gösterilebilecek örnek çıktı

Sıra	Önerilen İçerik	Tür	Skor
1	Interstellar	Bilim Kurgu	0.91
2	Inception	Bilim Kurgu	0.88
3	Dune	Bilim Kurgu	0.84

9. Proje formatı

1. Kaynak kodlar düzenli klasör yapısında olmalıdır.
2. Veri seti veya kullanılan örnek CSV dosyaları proje içinde bulunmalıdır.
3. README.md veya kısa rapor dosyasında proje amacı, kullanılan yöntem ve sonuçlar anlatılmalıdır.
4. Kod çalıştırıldığında en az bir kullanıcı için öneri üretebilmelidir.
5. Kod içinde anlaşılır değişken isimleri ve temel yorum satırları bulunmalıdır.

10. Sık yapılan hatalar

- Öneri üretirken kullanıcının zaten puan verdiği içerikleri tekrar önermek
- Pivot tabloda eksik değerleri yönetememek
- Veri setindeki item_id ve title ilişkisini karıştırmak
- Benzerlik skorunu yanlış yorumlamak
- Çok az veri ile elde edilen sonuçları kesin doğru kabul etmek
- Kod çalışsa bile neden o önerinin üretildiğini açıklayamamak

11. Bonus geliştirmeler

- Sadece film ya da sadece kitap filtresi eklemek
- Kategori bazlı öneri üretmek
- Kullanıcıdan etkileşimli olarak kullanıcı numarası almak
- Sonuçları recommendations.csv olarak dışa aktarmak
- Basit bir arayüz hazırlamak
- User-based ve item-based yöntemleri aynı projede karşılaştırmak

13. Son söz

Bu proje, sizler için çok değerlidir. Lütfen dikkat ederek planlı bir şekilde projeyi yapınız.

Eğitmen notu: Tahmini Projeyi geliştirme süresi 2 haftadır.

MsC Hamit MIZRAK